

DCA0121 – INTELIGÊNCIA ARTIFICIAL APLICADA

Aula 10 – Algoritmos Genéticos

Prof. Marcelo Augusto Costa Fernandes

mfernandes@dca.ufrn.br

Introdução

- Algoritmos de busca baseados no mecanismo de seleção natural e genética.
- Utilizam a representação das soluções através de cadeias de bits (strings), que são modeladas à maneira das cadeias de DNA dos seres vivos orgânicos.
- Foram desenvolvidos por John Holland na Universidade de Michigan.
 - Objetivos do algoritmo original
 - Criar uma abstração para explicar rigorosamente o processo adaptativo dos sistemas naturais
 - Projetar sistemas de software artificial que conservassem os mecanismos mais importantes dos sistemas naturais.

Introdução

- Principais características dos sistemas biológicos:
 - Auto-reparo
 - Auto-orientação
 - Reprodução
 - Aprendizado
 - Evolução
- Obs: Estas características nem sempre encontram-se presentes nos sistemas artificiais

Para que servem?

- Busca e Otimização
- Amplamente utilizados, com sucesso, em problemas de difícil manipulação pelas técnicas tradicionais
- Eficiência X Flexibilidade

Características Gerais

- Utilizam uma codificação do conjunto de parâmetros (*indivíduos*) e não com os próprios parâmetros (*estados*);
- Vasculham várias regiões do espaço de busca de cada vez;
- Utilizam informações diretas de qualidade, em contraste com as derivadas utilizadas nos métodos tradicionais de otimização;
- Utilizam regras de transição probabilísticas e não regras determinísticas.

Características Gerais

Algoritmos Genéticos podem ser considerados como métodos
que trabalham com

Buscas Paralelas Randômicas Direcionadas

Diferenças entre Algoritmos Genéticos e métodos Tradicionais

- GA's trabalham com uma codificação do conjunto de parâmetros, não com os próprios parâmetros
- GA's realizam a busca sobre uma população de pontos, não sobre um único ponto
- GA's utilizam a informação do resultado da função objetivo, não derivadas ou qualquer outro conhecimento auxiliar
- GA's usam regras de transição probabilísticas, não regras determinísticas.

Funcionamento Fundamental

1. Gerar População Inicial
2. Descartar uma parte dos Indivíduos menos aptos
3. Aplicar operadores de reprodução
4. Aplicar operadores de mutação
5. Se o critério de parada foi satisfeito, encerrar. Senão, voltar ao passo 2.

Modelagem

- Indivíduos X Estados
- Cada indivíduo possui um *código genético*
- Esse código é chamado cromossomo
- Tradicionalmente, um cromossomo é um vetor de bits
- Vetor de bits nem sempre é o ideal

Questões importantes

- Como criar cromossomos e qual tipo de codificação usar?
- Como escolher os pais para a realização do crossover?
- A geração de uma população a partir de duas soluções pode causar a perda da melhor solução. O que fazer?

Codificação binária

- É a mais comum devido a sua simplicidade
- Cada cromossomo é uma string de bits – 0 ou 1
 - Crom: A = 1 0 1 1 0 0 1 0 1 1
 - Crom: B = 1 1 1 1 1 1 0 0 0 0
- Exemplo de uso: problema da mochila
- Codificação: Cada bit diz se um elemento está ou não na mochila

Codificação por permutação

- Mais usado em problemas de ordenação
- Cada cromossomo é uma string de números que representa uma posição numa sequência
 - Crom A: 1 5 3 2 6 4 7 9 8
 - Crom B: 8 5 6 7 2 3 1 4 9
- Exemplo de uso: problema do caixeiro viajante
- Codificação: os cromossomos descrevem a ordem em que o caixeiro irá visitar as cidades

Codificação por valor

- Usado em problemas onde valores mais complicados são necessários
- Cada cromossomo é uma sequência de valores
 - Crom A: 1.2324 5.3243 0.4556 2.3293 2.4545
 - Crom B: ABDJEIFJDHDIERJFDLDFLFEGT
 - Crom C: (back), (back), (right), (forward), (left)

Codificação por valor (Cont.)

- Exemplo de uso: dada uma estrutura, encontrar pesos para uma rede neural
- Codificação: Valores reais num cromossomo representam pesos em uma rede neural

Operadores Fundamentais

- Seleção Natural
- Manipulação Genética por Mutação
- Manipulação Genética por Reprodução

Seleção Natural

- Princípio básico para o direcionamento da evolução de uma dada população
- Utiliza uma função de avaliação para medir a *aptidão* de cada indivíduo
- Essa aptidão pode ser *absoluta* ou *relativa*
- Existem vários métodos de seleção

Seleção

- A função de seleção é escolher os elementos da população que participarão do processo de reprodução
 - Selecionar os pais dos indivíduos que estarão presentes na nova população.
- Esta escolha deve ser feita de tal forma que os membros da população mais adaptados ao meio ambiente, tenham maior chance de reprodução

Principais Métodos de Seleção Natural

- Roleta
- Torneio
- Amostragem Universal Estocástica

Exemplo

- **Exemplo de um Algoritmo Genético simples**

- População Inicial: Strings de 5 bits

- 01101 $f(x) = x^2 \gg 13^2 = 169$
- 11000 $f(x) = x^2 \gg 24^2 = 576$
- 01000 $f(x) = x^2 \gg 8^2 = 64$
- 10011 $f(x) = x^2 \gg 19^2 = 361$

Exemplo

Nº	String	Fitness	% do total
1	01101	169	14,4
2	11000	576	49,2
3	01000	64	5,5
4	10011	361	30,9
Total	-----	1170	100,0


População Exemplo

<i>Indivíduo</i>	<i>Aptidão Absoluta</i>	<i>Aptidão Relativa</i>
1	2	0,052631579
2	4	0,105263158
3	5	0,131578947
4	9	0,236842105
5	18	0,473684211
<i>Total</i>	38	1

Método da Roleta

- Coloca-se os indivíduos em uma roleta, dando a cada um uma “fatia” proporcional à sua aptidão relativa
- Depois roda-se a agulha da roleta. O indivíduo em cuja fatia a agulha parar permanece para a próxima geração
- Repete-se o sorteio quantas vezes forem necessárias para selecionar a quantidade desejada de indivíduos


Roleta - Exemplo



Método do Torneio

- Utiliza sucessivas *disputas* para realizar a seleção
- Para seleccionar k indivíduos, realiza k disputas, cada disputa envolvendo n indivíduos escolhidos ao acaso
- O indivíduo de maior aptidão na disputa é seleccionado
- É muito comum utilizar $n = 3$


Torneio - Exemplo



Amostragem Universal Estocástica - *SUS*

- *SUS — Stochastic Universal Sampling*
- Semelhante à Roleta, mas para selecionar k indivíduos utiliza k agulhas igualmente espaçadas, girando-as em conjunto uma só vez
- Apresenta resultados menos variantes que a Roleta

SUS - Exemplo




Operador de Mutação

- Operador randômico de manipulação
- Introduz e mantém a variedade genética da população
- Garante a possibilidade de se alcançar qualquer ponto do espaço de busca
- Contorna mínimos locais

Operador de Mutação

- É um operador genético secundário
- Se seu uso for exagerado, reduz a evolução a uma busca totalmente aleatória
- Logo um indivíduo sofre mutações com probabilidade baixa (normalmente entre 0,001 e 0,1)

Exemplo de Mutação



Operador de Cruzamento

- Também chamado de *reprodução* ou *crossover*
- Combina as informações genéticas de dois indivíduos (*pais*) para gerar novos indivíduos (*filhos*)
- Versões mais comuns criam sempre dois filhos para cada operação


Operador de Cruzamento

- Operador genético principal
- Responsável por gerar novos indivíduos *diferentes* (sejam melhores ou piores) a partir de indivíduos já promissores
- Aplicado a cada par de indivíduos com alta probabilidade (normalmente entre 0,6 e 0,99)


Abordagens para Cruzamento

- Cruzamento Um-Ponto
- Cruzamento Multi-Pontos
- Cruzamento Uniforme


Cruzamento Um-Ponto



Cruzamento Multi-Ponto



Cruzamento Uniforme



Tipos de Substituição

- Substituição por geração
 - A cada geração os N filhos gerados substituem seus pais
- Substituição por geração com elitismo
 - É mantida um quantidade fixa de pais na troca de geração
 - O *Elitismo* garante uma cópia do melhor indivíduo na geração seguinte.
- Substituição com estado fixo
 - A cada geração k filhos substituem
 - k pais
 - k piores indivíduos
 - k indivíduos mais velhos

Parâmetros Genéticos

- Tamanho da população
 - Condiciona a qualidade da solução obtida e o tempo de processamento.
- Taxa de cruzamento
 - Define a probabilidade com a qual 2 indivíduos da população serão cruzados para gerar nova descendência.
- Taxa de mutação
 - Define a probabilidade no qual um indivíduo pode sofrer mutação
- Taxa de substituição
 - Define a percentagem de população que será substituída em cada transição de gerações.
- Critério de parada
 - Quando se atinge uma solução com um determinado valor de aptidão;
 - Quando se atinge um determinado limite temporal;
 - Quando se atinge um determinado número de gerações.

Parâmetros Genéticos

- Tamanho da população
 - Se pequeno
 - Executa rápido
 - Baixa qualidade
 - Se grande
 - Boa qualidade
 - Custo computacional

Parâmetros Genéticos

- Taxa de cruzamento
 - Pequeno
 - Convergência demorada
 - Grande
 - Perda de material genético
 - Entre 60% e 100%

Parâmetros Genéticos

- Taxa de mutação
 - Previne a permanência em espaço de busca limitado
 - Máximos locais
 - Se muito elevado
 - Busca aleatória (ruim)
- Menor que 1%

Parâmetros Genéticos

- Taxa de substituição
 - Quantidade de indivíduos a ser descartada
 - Bons sobrevivem
 - Menos aptos são excluídos
 - Material genético desconsiderado

Esboço do algoritmo

- **[Início]** Geração aleatória de uma população de n cromossomos
- **[Adaptação]** Verificar a **função objetiva** $f(x)$ de cada cromossomo x
- **[População]** Cria-se uma nova população pela repetição a seguir:
 1. **[Seleção]** Selecione um par de cromossomos da população de acordo com a adaptação de cada um (os mais bem adaptados tem maior chance de serem escolhidos)
 2. **[Crossover]** Produza dois descendentes (filhos) realizando crossover com os cromossomos dos pais. O ponto para a realização do crossover deve ser aleatório.
 3. **[Mutação]** Com uma certa probabilidade, o descendente sofre mutação em cada locus (posição no cromossomo).
 4. **[Aceitação]** Coloque os descendentes em uma nova população, juntamente com a melhor solução da geração velha

Esboço do algoritmo (Cont.)

- **[Troca]** Substitua a população velha pela nova
- **[Teste]** Se a condição de finalização é satisfeita, **pare**, e retorne a melhor solução da população atual
- **[Adaptação]**
- **[Laço]** Volte ao passo 1